基于机器学习模型的中风预测分析

数学与统计学院　统计学专业

116032020074 洪亮 指导教师：方榕娟

【摘要】 本文通过逻辑回归、决策树和随机森林模型探索机器学习在中风风险预测中的应用。我们对包含年龄、性别、高血压等影响因素的数据集进行了分析。结果表明，随机森林模型在各项性能指标上均优于逻辑回归和决策树模型，证明了其在预测中风风险上的有效性。研究也指出了数据不平衡、特征工程限制和模型解释性不足等问题，建议未来工作中进行更深入的模型优化和探索。本研究旨在为中风预防提供早期预测工具，支持制定更有效的干预措施。

【关键词】机器学习；中风预测分析；决策树；随机森林；逻辑回归

1．引言

1.1 研究背景及意义

中风（脑卒中），作为全球范围内主要的死亡和残疾原因之一，对公共卫生构成了重大挑战。根据世界卫生组织（WHO）的报告，中风每年导致约 600 万人死亡，是全球第二大致死原因。此外，中风是导致成人获取性残疾的主要原因，对个体、家庭及社会造成了巨大的经济和社会负担。随着全球人口老龄化的加速，预计中风的负担将进一步增加，尤其是在低收入和中等收入国家。

在过去的近 30 年中，我国脑卒中患病率明显上升，目前我国脑卒中现患人数高居世界首位，我国脑卒中发病率呈显著上升趋势，与发达国家降低趋势相反。相关研究估计，2030 年我国脑卒中的发生率将比 2010 年增加约 50%[1]。根据《中国脑卒中防治报告（2023）》，我国 40 岁及以上人群脑卒中现患人数达 1242 万，且发病人群呈年轻化。我国平均每 10 秒就有 1 人初发或复发脑卒中，每 28 秒就有 1 人因脑卒中离世；幸存者中，约 75%留下后遗症、40%重度残疾，病患家庭将因此蒙受巨大的经济损失和身心痛苦。

目前对于脑卒中没有特定的治疗手段，主要是以前期预防和干预为主，因此有效的预测和分析脑卒中高危人群成为一个具有重要意义的课题。通过预测分析可以早期识别高风险人群，为这些人群提供个性化的预防建议，如生活方式的调整、定期医学检查和早期药物干预。有效的预防措施能够显著降低中风的发病率，进而减少因中风导致的死亡和残疾。

1.2 国内外研究现状

1.2.1 机器学习模型对于疾病预测的研究

在国外，使用机器学习模型预测疾病的早期例子可以追溯到上世纪 80 年代末到 90 年代初，当时这一领域处于探索阶段，主要依赖于较为简单的算法和有限的数据集。1980 年代末，David Aha 和 Dennis Kibler 在加州大学尔湾分校工作时开发了一个名为 IBL（Instance-Based Learning）的算法，这是一种简单的基于案例的学习方法，可以应用于医疗诊断问题。尽管这项工作的直接焦点不完全是疾病预测，但它为后来在医学领域使用机器学习提供了早期的理论基础。1999 年，Lundin M 等 5 人将人工神经网络模型用于癌症的预后系统，对乳腺癌特异性存活率进行预测，训练乳腺癌患者的一些临床病理变量，用于对 5 年、10 年、15 年的乳腺癌特异性存活率的预测，该模型有着较高的准确率[2]。进入 21 世纪后，随着计算技术的飞速发展和大数据时代的到来，使用机器学习模型预测疾病的研究迅速增多，并且取得了显著的进展。2000 年代中期，Andrew Ng 和

Geoff Hinton 等在深度学习领域的突破，这些研究人员对卷积神经网络（CNN）和深度神经网络（DNN）的发展做出了重大贡献，为医疗影像分析（如皮肤癌检测、眼病诊断等）提供了强大的工具。他们的工作促进了深度学习技术在医学诊断、疾病预测和健康监测中的应用。2017 年，Alkeshuosh 等人利用粒子算法用于诊断心脏病，并与基于 C4.5 的决策树算法进行对比，发现粒子群优化算法有着更良好的性能[错误!未找到引用源。]。

虽然国内的研究起步较晚，但仍取得了许多不错的成果。2009 年，张娅莉和喇果彦运用 GRNN 建立模型对糖尿病和高脂血症疾病进行预测，取得较高的准确率[4]。2018 年，任福龙等人提出了基于代价敏感的半监督 Bagging(CS-SemiBagging)的糖网分级方法，这种半监督 Bagging 的方法既可以在病炤未标注的情况下进行分级，又可以解决在类别不平衡的问题下对分类算法的影响[5]。2020 年面对 COVID-19 疫情时，浙江大学的研究团队开发了一种基于深度学习的人工智能模型，能够从 CT 影像中快速识别出新冠肺炎病例。该模型在提高诊断速度和准确性方面发挥了重要作用，为抗击疫情提供了技术支持。2021 年，朱宵彤等人针对心血管疾病预测提出了基于一维卷积神经网络模型，并与逻辑回归模型和粒子群优化算法进行对比，其准确率有着明显的提高[6]。

这些早期的研究不仅证明了机器学习技术在医疗和生物信息学领域的应用潜力，而且为后来的研究者提供了重要的理论和实践基础。随着时间的推移，更先进的算法和技术，以及对大数据的访问，极大地扩展了机器学习在疾病预测中的应用范围和效果。

1.2.2 机器学习模型中风预测研究现状

近年来，国外在中风预测分析方面的研究越来越多地采用机器学习模型，这些模型能够处理复杂的数据集并从中发现潜在的风险因素和模式。2015 年，Manuel 等人从 2001 年开始对 82259 个安大略人开展一项以人群为基础的调查，观察了 3236 例中风事件，构建一个用来总结健康行为和压力所致的中风事件的累计相对风险的指数，人们可以通过这个指数来进行自身中风评估[错误!未找到引用源。]。还有随机森林，这是一种集成学习方法，通过构建多个决策树来提高预测的准确性和稳定性。在中风预测研究中，随机森林被用于分析和整合多种风险因素，如年龄、血压、糖尿病等，从而提高预测中风风险的准确度。常见的还有深度学习（Deep Learning），尤其是卷积神经网络（CNN）和循环神经网络（RNN），在图像识别、自然语言处理等领域表现出色。在中风预测研究中，深度学习被用于分析医学影像（如 MRI、CT 扫描图像）以及处理大型临床数据集，以识别中风的早期信号和风险模式。

而国内关于中风预测分析的研究也越来越多地采用机器学习模型，这些模型通过分析大量的健康数据来预测中风风险，提高预测的准确性和效率。2019 年，吴菊华等人对诱发中风的最危险因素进行识别，筛选出 12 个重要因素进行建模，运用多层感知机神经网络模型进行预测，得到较高的准确率[8]。还有基于电子健康记录（EHR）的机器学习模型，国内一些研究通过分析医院电子健康记录中的数据，使用机器学习算法（如随机森林、支持向量机、神经网络等）来预测中风风险。这些研究能够综合考虑多种风险因素，如患者的生化指标、生活习惯和家族病史等，从而提供个性化的中风风险评估。

也有研究利用人工神经网络（ANN）来预测中风风险，这些模型能够处理非线性和复杂的数据关系，提高预测的准确性。ANN 在处理大量患者数据时特别有用，能够从中发现潜在的风险模式。

这些研究成果展示了机器学习技术在中风预测和管理中的应用前景。随着数据科学和人工智能技术在医疗领域的持续发展，预计将有更多创新的机器学习模型被开发出来，以进一步提高中风预测的准确性和实用性。

1.3 论文研究内容与目的

本文旨在探索和评估机器学习技术在中风风险预测中的应用和有效性。中风作为一种主要的健康威胁，对个体和社会产生了重大影响，包括长期残疾、生活质量下降和高昂的医疗费用。因此，准确预测个体中风风险具有重要意义，可以帮助医疗专业人员及时采取预防措施，减少中风的发生率和相关负担。

研究内容包括使用不同的机器学习模型（逻辑回归、决策树、随机森林）对中风预测进行建模和评估。通过对具有潜在预测价值的多种特征（如年龄、性别、高血压、心脏疾病等）进行综合分析，本研究旨在确定最有效的预测模型。此外，本文还探讨了模型性能的不同方面，包括准确率、精确度、召回率和 F1 分数等指标，以评估和比较各模型的预测能力。

研究的目的不仅在于评估机器学习模型在中风预测中的表现，而且在于识别存在的挑战和局限性，如数据不平衡、特征选择和模型的可解释性问题。通过对这些关键问题的深入分析和讨论，本研究旨在为未来的研究提供方向，特别是如何通过改进机器学习模型和方法来提高中风风险预测的准确性和实用性。最终，本文期望贡献于公共健康领域，通过早期预测和预防措施，减轻中风的社会和经济负担。

2. 相关理论介绍

2.1 机器学习模型相关原理

机器学习是一种使计算机能够从数据中学习并做出预测或决策，而无需进行显式编程的技术。它主要分为监督学习、非监督学习、半监督学习和强化学习。这些类型的学习各有其特点和应用领域。本次研究中使用的逻辑回归模型、决策树与随机森林都属于监督学习，它通过使用一组已知的输入输出对（即带有标签的训练数据）来训练算法，从而使算法能够预测出新未见过数据的输出。这种方法的核心是从标记的训练数据中学习或建立一个模型，并根据这个模型预测新数据的输出。

2.1.1 逻辑回归模型

逻辑回归是一种广义线性模型（GLM），用于处理因变量是二元分类（如有/无中风）的情形。模型通过估计事件发生的概率与一组解释变量（或特征）之间的关系，基于 Sigmoid 函数或逻辑函数将线性预测值映射到 0 和 1 之间的概率。

假设变量间存在线性关系。模型的线性部分是解释变量（自变量）的线性组合，即：

$$\eta = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n \tag{2-1}$$

其中 η 是对数几率，β_0 是截距项，$\beta_1, \beta_2, \ldots \beta_n$ 是回归系数，$x_1, x_2, \ldots x_n$ 是解释变量。接着使用 Sigmoid 函数（也称为逻辑函数）将线性回归模型的输出值映射到 $(0,1)$ 之间，表示概率：

$$p = \frac{1}{1+e^{-\eta}} \tag{2-2}$$

这使得逻辑回归能够输出一个介于 0 和 1 之间的概率值，代表特定结果发生的概率。在逻辑回归中，模型预测的是给定输入 X 下，目标变量 Y=1 的概率，记为 $P(Y=1|X)$。通过 Sigmoid 函数，这个概率表示为：

$$P(Y=1|X) = p \tag{2-3}$$

若 $P(Y=1|X) > 0.5$，我们预测 Y=1（已中风）；否则 Y=0（未中风）。而逻辑回归模型的参数估计通常使用最大似然估计（MLE）。最大似然估计是一种根据已有数据寻找参数估计值的方法，通过最大化似然函数来找到参数的最佳估计。

2.1.2 决策树模型

决策树是一种常用的机器学习算法，用于分类和回归任务。它通过从数据中学习简单的决策规则来构建模型，这些规则基于输入特征的值。决策树模型的目的是创建一个模拟决策过程的树结构，以预

测目标变量的值。通过创建一系列决策规则来预测类别响应变量，将可能发生的结局以一棵倒置的树形流程图呈现,这棵树由节点和枝干组成。节点可分为根节点、叶节点和内部节点。根节点指包含整个数据集的节点，叶节点表示决策结果，内部节点表示一个特征或属性。构建决策树时首先进行特征选择，在每个节点，算法选择最佳的特征来分割数据。选择标准通常基于特征分割后数据纯度的增加，常用的方法包括信息增益（ID3 算法）、信息增益比（C4.5 算法）和基尼不纯度（CART 算法）。接着使用选定的特征进行数据分割，每个分割创建新的节点。这个过程递归进行，直到满足特定的停止条件，如节点达到最大深度、节点中的样本数量少于最小分割限制或节点的纯度（如所有样本属于同一类）。决策树可根据数据情况进行分类生长,但充分生长的树可能不是一棵最佳树,因为决策树生长太大太完美后，会过度解读数据的特征，不利于准确反映出数据的特征，这种现象在数据挖掘中称为“过度拟合”。为防止过拟合，通过剪枝来简化决策树。剪枝可以在树构建过程中（预剪枝）或构建完成后（后剪枝）进行。

2.1.3 随机森林模型

随机森林是一种集成学习算法，用于分类、回归和其他任务，通过构建多个决策树在训练时并输出分类（对于分类问题）或平均预测（对于回归问题）的模式来工作。它结合了多个决策树的预测能力，以提高整体模型的准确性和稳定性。

随机森林使用的是自助采样（也称为 bootstrap sampling）的采样思想，随机有放回的从 m 个样本中抽取 n 个样本作为训练数据，再从所有的特征中选出 t 个特征建立决策树，这个过程重复 k 次就可以得到 k 棵决策树，这 k 棵决策树进行组合就得到了一个随机森林。当在处理回归问题时，随机森林通过将每棵决策树预测的数值进行简单平均处理，作为随机森林的输出值，即回归预测结果；对于分类问题，每棵决策树都会给出分类的结果，然后随机森林再根据多数投票法的思想， 选择得票最多的类别，作为随机森林的输出值，即分类预测结果。

2.2 模型的评估方法

混淆矩阵（Confusion Matrix）是评估分类模型性能的一个重要工具，尤其是在监督学习中。它是一个表格，用于展示模型预测结果与实际结果之间的关系，使我们能够清晰地看到模型在各个类别上的表现。在二分类问题中，混淆矩阵包含四个部分：真正例（True Positives, TP），即模型正确预测为正类的数量，在此研究中指的是正确预测中风的案例数；假正例(False Positives, FP)，即模型错误预测为中风，但实际为没中风患者的数量；真负例(True Negatives, TN)，即模型正确预测为没中风的数量；假负例(False Negatives, FN)，模型错误预测为没中风，但实际为中风患者的数量。

2.2.1 准确率与精确率

准确率（Accuracy）是模型正确预测正类和负类的总体比例。在中风预测模型中，准确率表示模型正确识别中风和非中风患者的总比例，其计算公式为：

$$\frac{(TP+TN\ `}{(TP+FP+TN+FN)} \tag{2-4}$$

精确率（Precision）是模型预测为正类（中风）中，实际为正类的比例。在中风预测中，它表示被预测为中风患者中实际患有中风的比例,其计算公式为：

$$\frac{TP}{(TP+FP)} \tag{2-5}$$

2.2.2 召回率与特异性

召回率（Recall）是实际为正类中，模型正确识别为正类的比例。在中风预测中，它表示所有实际中风患者中，被模型正确识别出来的比例，其计算公式为：

$$\frac{TP}{(TP+FN)} \tag{2-6}$$

特异性（Specificity）是实际为负类中，模型正确识别为负类的比例。在中风预测中，它表示所有实际非中风患者中，被模型正确识别出来的比例，其计算公式为：

$$\frac{TN}{(TN+FP)} \tag{2-7}$$

F1 分数可以用来预测模型处理结果的好坏,是精确率和召回率的调和平均，提供了两者之间的平衡度量。在中风预测中，F1 分数帮助评估模型在不牺牲召回率的情况下保持较高精确率的能力，或者反之。F1 表达式为：

$$2\times\frac{precision\times recall}{precision+recall} \tag{2-8}$$

2.2.3 ROC 曲线

ROC 曲线（Receiver Operating Characteristic curve）是一种评估二分类模型性能的工具，通过描绘在不同阈值设置下真正例率（召回率）与假正例率（1-特异性）之间的关系来展示模型的诊断能力。其中假正例率（False Positive Rate, FPR）表示所有实际负例中，错误地被模型识别为正例的比例。

ROC 曲线提供了一个在不同阈值下模型性能的全面视图，帮助我们理解模型在区分两个类别（如中风和非中风）的能力。曲线下的面积（Area Under the ROC Curve, AUC）用于量化模型整体的诊断能力。AUC 的值范围从 0 到 1，其中较高的 AUC 值表示模型具有更好的性能。AUC = 0.5 表示模型没有区分能力，等同于随机猜测；AUC 接近 1 表示模型具有很高的区分正负例的能力。

3．不平衡数据的处理

3.1 数据说明

本文选取的数据来源于 kaggle 数据平台（(https://www.kaggle.com/）公开的中风数据集，数据集含有 5111 个身份不同，家庭情况不同的人的特征数据，可以基本满足训练和验证模型的需要。

目标变量为 stroke，是一个二分类变量，有“0”和“1”两个值，分别表示没患中风的观测者与

患中风的观测者。对目标变量进行分析，患病与没患病的情况为：0（不患病）人数为 4861 人，1（患病）人数为 249 人。可以看出，患中风患者与不患中风患者的数据个数相差极大，其中患病人数约占总体数据的 4.9%，数据比例极度不平衡，因此需要进行数据不平衡处理。

3.2 处理不平衡数据

处理不平衡数据是机器学习中的一个常见问题，特别是在分类任务中。当一个数据集中的类别分布不均衡时，模型可能会偏向于多数类，从而忽略少数类，这会影响模型的泛化能力和对少数类的预测性能。常见方法有欠采样(under-sampling)和过采样(over-sampling)。本文使用的 ROSE 是通过随机采样技术与合成样本生成策略相结合来平衡数据集。具体来说，ROSE 通过在特征空间中的数据点周围生成新的数据点来工作。这个过程不仅仅涉及到复制现有的少数类样本，而是在少数类样本的周围生成新的、合成的样本点，从而增加少数类的样本数目。同时，它也可以对多数类样本进行下采样，以进一步平衡类分布。

运用 ROSE 包对中风数据集进行处理后得到的目标变量的分布情况为：0（不患病）人数为 2571 人，1（患病）人数为 2539 人。可见患中风患者与不患中风患者的比例已经相差不大，说明数据不平衡问题已消除，接下来将用这个以平衡后的数据集进行建模分析，将这个平衡后的数据集命名为“rose_data”。

4. 基于逻辑回归构建中风预测模型

4.1 模型构建

4.1.1 数据预处理

本文的数据预处理分为两个步骤：数据清理和数据规范。

首先进行数据清理，数据清理是通过填补空缺值，删除或者解决数据的不一致性 来达到清理数据的目的。因为文中的“id”列通常为记录的唯一标识符，对于模型的训练和预测没有帮助，所以把它移除。经过分析，平衡后的数据集 rose_data 的十一个特征（移除 id 列后）除了 bmi 特征外，其他特征均无缺失值。为了进行有效的模型训练，我们需要处理 bmi 特征的缺失值。常见的处理方法包括填充缺失值（例如，使用中位数或平均值）或删除含有缺失值的记录，本研究选择中位数填充缺失值，选择中位数作为填充值是因为它对异常值具有较好的鲁棒性，特别是在数据分布可能偏斜的情况下。

第二步进行数据的规范，数据采集的信息是多样化的，为了其能在逻辑回归模型中 得到更好的处理，需要将数据的格式统一，对分类变量如 gender(性别），ever_married（婚姻状况，work_type（工作类型），Residence_type（居住类型），smoking_status（吸烟状况）进行独热编码，转换为数值形式，使其可以被模型正确处理。

4.1.2 训练模型

在构建训练模型前先进行数据集的划分，这是为了防止过拟合，确保模型不仅仅是记住了训练数据的特征，而是能够捕捉到数据背后的一般规律，并在未见过的数据上也能表现良好。通过划分训练集使模型可以公正地评估和比较模型的性能。本研究使用“createDataPartition”函数按照指定的比例（此处为 80%作为训练集）划分数据集，确保模型能在独立的数据上进行测试和评估。接着使用利用“glm”函数（代表广义线性模型）进行逻辑回归模型的训练，最后基于混淆矩阵，评估模型的准确性、召回率、精确率等指标对模型的性能进行评估。

4.2 结果分析

由显著性检验可以得到下表：

表 4-1　逻辑回归模型的显著性检验表

变量名	回归系数	标准误	t 值	p 值
Age	0.0628	0.002688	23.365	<2e-16
avg_glucose_level	0.004371	0.0006964	6.276	3.46e-10
heart_disease	0.6503	0.1176	5.528	3.24e-08
hypertension	0.5192	0.09455	5.491	4.00e-08

由图 4-1 可知对中风有显著性影响的变量有年龄、平均血糖水平（avg_glucose_level）、不吸烟（smoking_statusnever smoked）、高血压（hypertension）和心脏疾病（heart_disease），其中计算得到年龄系数为 0.0628，表示年龄每增加一岁，发生事件的对数几率增加 0.0628，且非常显著（p < 2e-16），高血压和心脏疾病的系数分别为 0.5192 和 0.6503，都具有正向效应且非常显著，说明有这些疾病的人发生事件的概率更高。许多变量（如性别、婚姻状况、工作类型、居住类型和 BMI）的系数不是很显著，或者影响较小。

还可以得到混淆矩阵为：

表 4-2　逻辑回归模型的混淆矩阵表

Predction(预测） Referrnce（实际）	0（没中风）	1（中风）
0（没中风）	387	127
1（中风）	116	391

由此混淆矩阵可以通过第三章的公式计算得到：准确率（Accuracy）为 76.20%，表示模型正确预测正类（中风）和负类（没中风）的比例，这是一个相对较高的准确率，表明模型在整体上能够较好地进行预测；精确率（Precision）为 75.48%，表示被预测为正类中，实际为正类的比例，这个数值较高，说明模型在预测正类时有较高的可信度；召回率（Recall）77.12%，表示所有实际正类中，被正确预测为正类的比例，较高的召回率表明模型能够较好地识别正类样本；F1 分数为 76.29%，是精确率和召回率的调和平均数，用于综合考虑精确率和召回率的性能指标，这个分数接近精确率和召回率，说明模型在维持精确率和召回率之间的平衡方面表现良好；ROC 曲线下的面积（AUC）：0.762，表示模型区分正类和负类的能力，值越接近 1 表示性能越好，0.762 的 AUC 值表明模型具有较好的区分能力，但仍有提升空间。

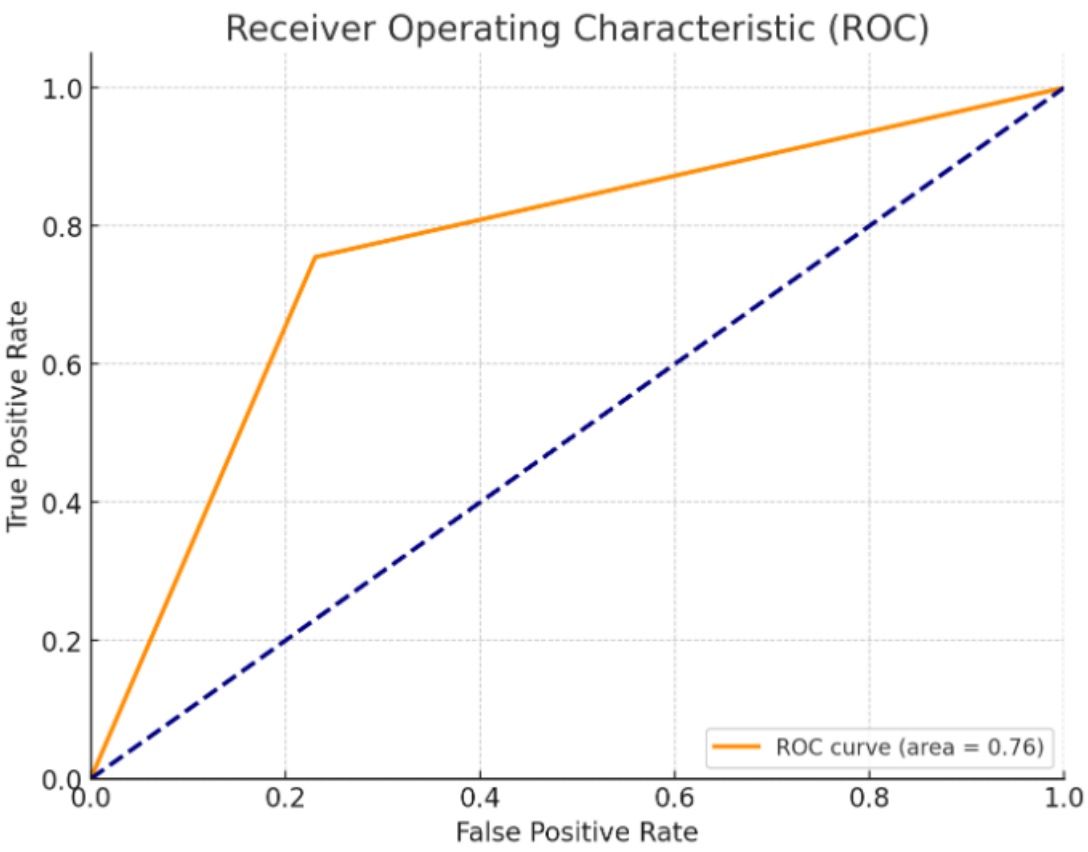

图 4-3　逻辑回归模型的 roc 曲线图

总的来说，这个逻辑回归模型表现出了良好的性能和准确性。它能够较为有效地进行分类预测，尤其是在准确率、精确率、召回率和 F1 分数方面。然而，每个指标都有其局限性，最佳的模型评估应考虑所有这些指标以及具体应用场景的需求，因此可能还需要进一步分析和调整模型。

5．基于决策树构建中风预测模型

5.1 模型构建

5.1.1 数据预处理

决策树模型的数据预处理和构建逻辑回归模型时步骤一样，先使用中位数填充 bmi 列的缺失值，然后确保 bmi 保持为数值变量并将分类变量转换为因子，来确保它们转换为数值型以适用于模型，最后移除不需要的列“id”。

5.1.2 构建模型

将平衡后的数据集 rose_data 导入 R 中，设定训练集样本量（traindata）与测试集样 本量（testdata）的参数分别为 8：2，R 语言读取数据后以随机抽取的方式从总体数据中抽出 80%作为训练集，剩下自动生成 20%的测试集，模型的建立采用的是训练集的数据，模型的准确性的验测采用的是测

试集数据。然后使用 rpart 函数从 rpart 包中训练一个决策树模型并使用 predict 函数进行预测，这里指定 type =“prob”以获取属于每个类别的预测概率。最后使用 confusionMatrix 函数从 caret 包中评估模型的性能，包括准确率、F1 分数等重要指标。

5.2 结果分析

由模型输出的决策树可视图为

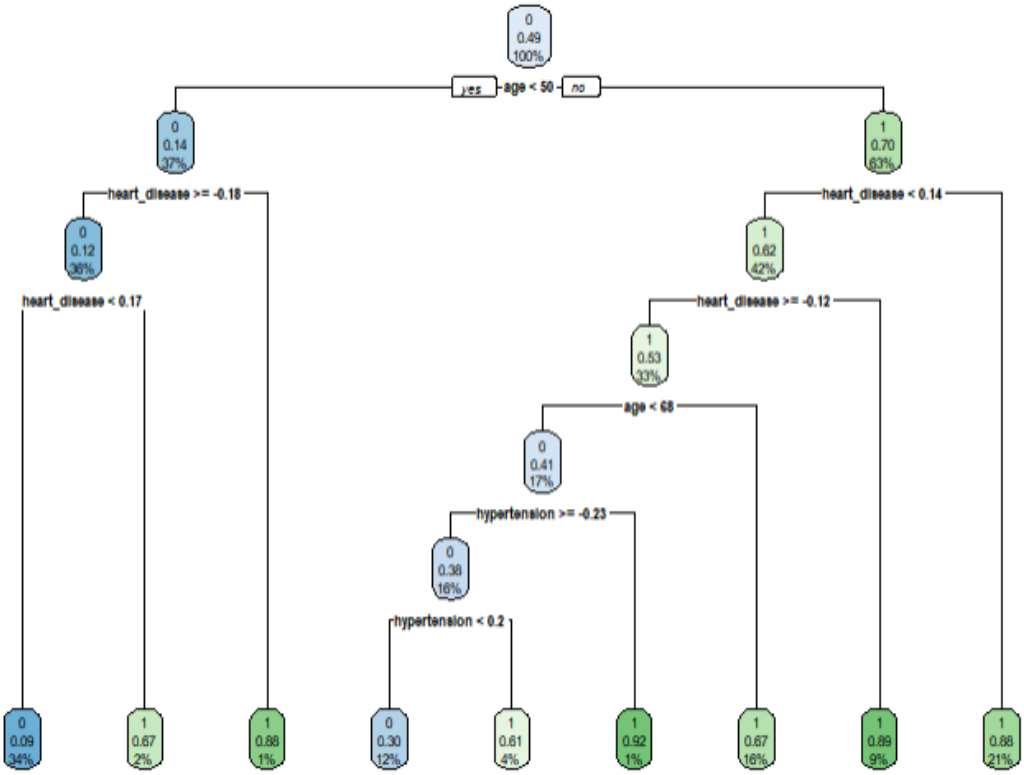

图 5-1　决策树的可视图

由图 5-1 可以看出年龄是中风风险分析中的主要分界点。50 岁被用作区分低风险和高风险群体的临界年龄。对于 50 岁及以上的个体，心脏疾病成为进一步划分中风风险的关键变量。心脏疾病患者的中风风险显著高于非心脏疾病患者。而在没有心脏疾病的个体中，再次使用年龄作为分割标准，68 岁成为另一关键节点。在 68 岁以下没有心脏疾病的群体中，高血压是区分中风风险的重要因素。树的终端节点（叶子）显示在这些条件下的预测中风风险，以百分比表示。左侧分支的概率较低，右侧分支的概率较高，尤其是在年龄大于 68 岁且有心脏疾病的群体中。

除了决策树可视图外还得到了混淆矩阵：

表 5-1　决策树的混淆矩阵表

Predction(预测)	0（没中风）	1（中风）

Referrnce（实际）		
0（没中风）	362	136
1（中风）	78	446

由混淆矩阵我们可以得到准确率（Accuracy）为 79.06%，这意味着模型正确预测了约 79.06%的情况。这是一个相对较高的准确率，表明模型在总体上是有效的；精确率（Precision）为 76.63%，较高的精确率说明在模型预测为正类的情况中，有大约 76.63%确实是正类。这表明模型在预测正类时较为可靠；召回率（Recall）为 85.11%，召回率较高，意味着模型能够捕捉到大多数正类，具体来说，模型正确识别了约 85.11%的实际正类案例；F1 分数（F1 Score）为 80.65%，F1 分数考虑了精确率和召回率的平衡,80.65%的 F1 分数表示模型在精确度和敏感度之间取得了良好的平衡。ROC 曲线下的面积(AUC)为 0.795，AUC 值接近 0.8，说明模型在区分正类和负类方面表现良好，能够以较高的真正率识别正类，同时保持一个较低的假正率。

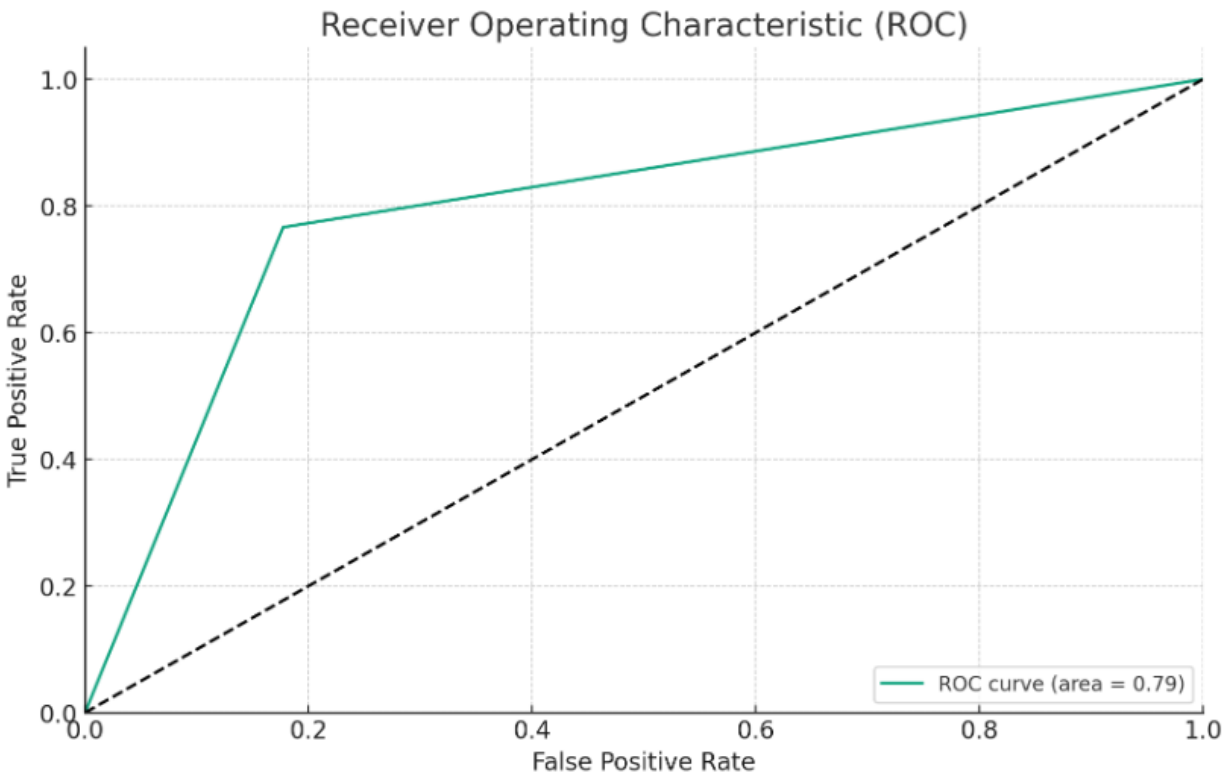

图 5-2　决策树模型的 roc 曲线图

总的来说，模型展示了相对较高的准确率和良好的分类能力。高精确率指出模型在预测正类时较少产生误判，而良好的召回率说明模型能够检出大部分实际正类。此外，F1 分数和 AUC 值均表明模型在平衡检出率和准确性方面表现良好。然而，是否可以接受这个模型的性能还取决于具体应用的需求以及与其他模型的比较。如果在特定应用中对某些错误的容忍度较低，可能需要进一步优化模型。

6. 基于随机森林构建中风预测模型

6.1 模型构建

6.1.1 数据预处理

随机森林的数据预处理与前两个模型基本一样，分为不相关特征的移除、数据类型转换以及缺失值填充三个步骤。首先去除 id 列，这一步从 rose_data 数据框中移除了名为 id 的列。id 列通常包含每条记录的唯一标识符，对于模型预测通常是不必要的，因为它不包含任何预测目标变量的信息。然后转换 bmi 列为数值类型。这一步通常是必要的，因为在数据集中，即使是数值型的数据，有时也可能因为格式问题而被读入为字符型。将这些数据转换为数值类型是确保数据能被正确处理和分析的重要步骤。最后填充 bmi 列的缺失值，这一步使用 bmi 列非缺失值的中位数来填充该列中的所有缺失值（NA）。使用中位数填充缺失值是处理缺失数据的常见方法，特别是当数据分布不对称或者包含异常值时，中位数比平均值更为稳健。

6.1.2 拟合模型

随机森林算法构建的基本步骤和原理如下：

1.引导聚合（Bootstrap Aggregating，即 Bagging）:随机森林通过创建决策树的“森林”，每棵树都使用随机抽样的训练数据集构建。这种抽样方法称为 Bootstrap，即从原始训练集中进行有放回的抽样，每次抽取一个样本，然后放回原始数据集，允许下次抽样时再次被抽到。这样每棵树的训练数据集都有所不同，一定程度上独立于其他树。

2.随机特征选择:在构建决策树的过程中，每次分裂节点时，算法会从所有特征中随机选取一个子集，并从中找出最佳的分裂特征。这种方法增加了模型的多样性，减少了过拟合的风险，因为它确保了每棵树不太可能在相同的特征上进行分裂。

3.决策树构建:每棵决策树都会尽可能地增长，通常不进行剪枝。决策树可以非常深，使得每棵树都有很高的方差，但由于整个模型涵盖了很多这样的树，所以整体的方差被平均，而偏差保持相对不变。

4.集成:随机森林算法中的每棵树都会独立地进行预测，最后这些预测结果会被整合起来。对于分类问题，通常采用多数投票的方式；对于回归问题，则是取平均值。整合的结果反映了整个模型的最终预测。

6.2 结果分析

经过分析可以得到随机森林模型的重要性评分

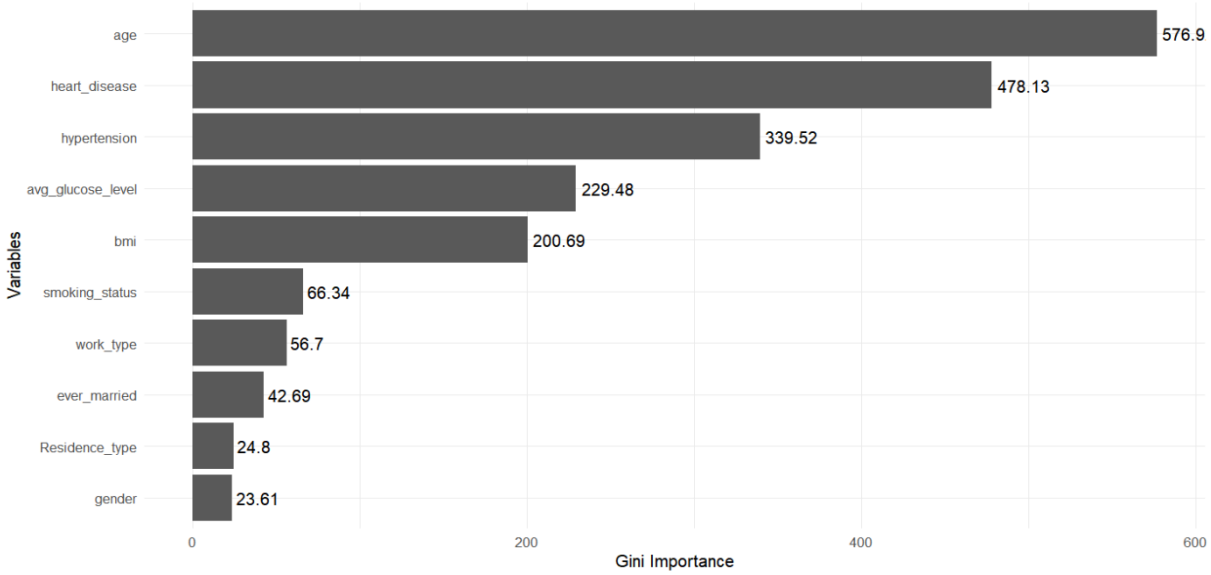

图 6-1　随机森林模型的重要性评分

由图 6-1 可以看出：年龄（age）的 Gini Importance 远高于其他变量，表明在决策树中，以年龄作为节点分裂的特征可以显著降低模型不纯度，这通常意味着年龄在预测中风方面非常重要。心脏疾病（heart_disease）和高血压（hypertension）在 Gini Importance 上排在第二和第三位，意味着这些医疗状况对于预测中风也非常关键。这些结论与医学上关于中风风险因素的知识相吻合，因为这些健康问题都被认为增加了患中风的风险。相对来说，性别（gender）和居住类型（Residence_type）在 Gini Importance 上相对较低，这可能意味着它们对于预测中风的贡献较小。

还可以得到混淆矩阵：

表 6-1　随机森林的混淆矩阵表

Predction(预测） Referrnce（实际）	0（没中风）	1（中风）
0（没中风）	437	77
1（中风）	61	446

由混淆矩阵可以根据前面的公式计算出：准确率（Accuracy）为 86.48%，意味着模型正确分类了 86.48%的样本。精确率（Precision）为 85.28%，意味着在模型预测为正类的样本中，有 85.28%实际为正类。召回率（Recall）为 87.97%，意味着在所有实际为正类的样本中，模型正确识别了 87.97%。F1 分数（F1 Score）为 86.60%，F1 分数是精确率和召回率的调和平均，接近 1 表示精确率和召回率之间的良好平衡。ROC 曲线下的面积（AUC）为 88.1%，表示模型区分正类和负类的能力非常好。

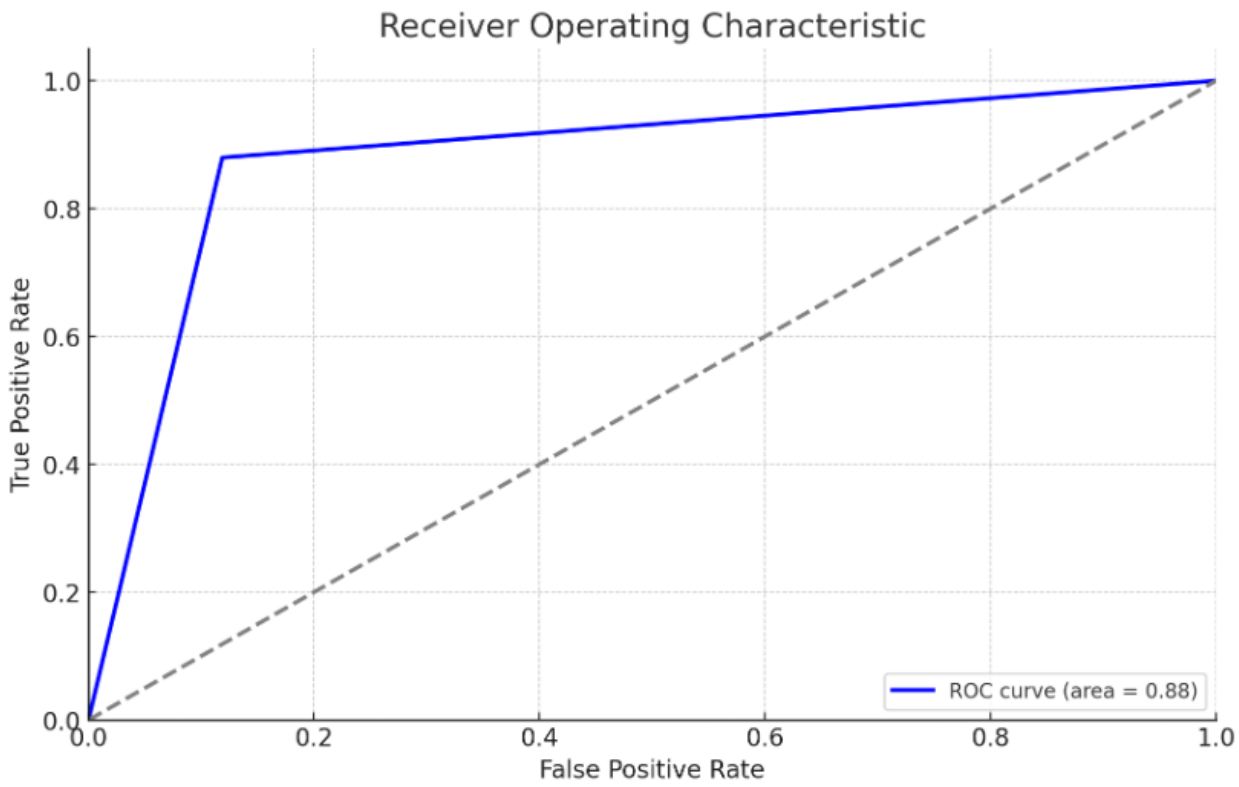

图 6-2　随机森林模型的 roc 曲线图

这些性能指标表明，模型在这个特定的测试数据集上表现出了良好的分类能力。准确率较高，说明大多数样本被正确分类。同时，精确率和召回率也很高，这说明模型在识别正类方面表现良好，并且在减少误分类的同时保持了较高的敏感性。AUC 值也非常高，这进一步证实了模型的良好预测性能。综上所述，模型的性能看起来相当好。

6.3 所有模型结果的对比分析

表 6-2　所有模型的实验对比表

	准确率	精确率	召回率	F1 分数	AUC 值
逻辑回归模型	76.20%	75.48%	77.12%	76.29%	76.2%
决策树模型	79.06%	76.63%	85.11%	80.65%	79.5%
随机森林模型	86.48%	85.28%	87.97%	86.60%	88.1%

比较这些指标，我们可以看到随机森林模型在所有主要性能指标上都优于其他两个模型，表现出最高的准确率、精确率、召回率、F1 分数以及 AUC 值。这表明随机森林模型在预测中风的分析中更为准确和可靠。决策树模型的召回率非常高，这意味着它能够很好地识别出正例，但其精确率稍低于随机森林，导致 F1 分数略低。逻辑回归模型在这三个模型中表现最差，所有指标均低于随机森林和决策树模型。然而，逻辑回归模型因其简单性而有时更易于解释。

7. 不足与展望

7.1 研究的不足

本次实验虽然从多个角度探索了中风预测问题，但仍存在一些不足之处，需要在未来的研究中加以改进：

1.特征工程限制：本次实验在特征工程方面相对较为简单，未能充分探索所有可能的特征组合和转换，这可能限制了模型捕捉数据潜在模式的能力。进一步的特征工程，如特征交叉、多项式特征，可能会揭示更多有助于预测的信息。

2.模型选择与调优：尽管实验考虑了逻辑回归、决策树和随机森林模型，但未涉及更广泛的模型和算法，如支持向量机、梯度提升机等。此外，模型的超参数调优也相对有限，未必达到了最优性能。未来工作可以更系统地探索模型选择和调优，以进一步提高预测准确率。

3.模型解释性不足：虽然随机森林模型表现优异，但其黑盒特性限制了模型决策过程的透明度和可解释性。在医疗健康领域，模型的可解释性是至关重要的，因此，未来研究需要探索如何平衡模型性能与解释性的关系，或者采用更具可解释性的模型。

7.2 研究展望

1.数据预处理和特征工程:进一步研究和实现更高级的数据预处理和特征工程技术,比如特征选择、维度降低等，可能会提高模型的性能。

2.模型调优:对现有模型进行超参数调优,使用如网格搜索和随机搜索的方法来找到最优参数组合，可能进一步提高预测精度。

3.深度学习：考虑使用深度学习模型，如卷积神经网络(CNN)或循环神经网络(RNN)，这些模型可能会在处理大规模或高维数据时表现更好。

4.更多数据：收集更多相关数据，特别是关于中风影响因素的更详细信息，可能会帮助模型更准确地学习和预测中风风险。

5.模型解释性：探索模型解释性方法，如特征重要性分析，可以帮助我们更好地理解模型的决策过程和预测结果的依据，从而在实际应用中提供更有价值的见解。

[1] 王亚楠,吴思缈,刘鸣.中国脑卒中 15 年变化趋势和特点[J].华西医学,2021,36(06):803-807.

[2] Lundin M, Lundin J, Burke H B, et al. Artificial Neural Networks Applied to Survival Prediction in Breast Cancer[J]. Oncology, 1999, 57(4): 281-286.

[3] Alkeshuosh A H, Moghadam M Z, Mansoori I A, et al. Using PSO Algorithm for Producing Best Rules in Diagnosis of Heart Disease[C]. Dubai, United Arab Emerates: IEEE, 2017, 306-311.

[4] 张娅莉，喇果彦. GRNN 神经网络在信息分析预测中的应用[J]. 数据采集与处理，2009，24(S1)：100-103.

[5] 任福龙，曹鹏，万超等. 结合代价敏感半监督集成学习的糖尿病视网膜病变分级[J]. 计算机应用，2018，38(7)：2124-2129.

[6] 朱宵彤，庞春颖，朱涵. 基于深度学习的心血管疾病预测模型[J]. 计算机应用，2021，41(S2)：346-350.

[7] Manuel D G, Meltem T, Richard P, et al. Predicting Stroke Risk Based on Health Behaviours: Development of the Stroke Population Risk Tool (SPoRT)[J]. Plos One,2015,10(12): e0143342.

[8] 吴菊华，张烁，陶雷，姜顺军. 基于神经网络的脑卒中风险预测模型研究[J]. 数据分析与知识发

现，2019，3(12)：70-75.

Predictive analysis of stroke based on machine learning models

HONG Liang 116032020074 Advisor：FANG Rong-juan

Major in Statistics School of Mathematics and Statistics

【**Abstract**】 In this paper, we explore the application of machine learning in stroke risk prediction through logistic regression, decision tree and random forest models. We analyzed a dataset containing influencing factors such as age, gender, and hypertension. The results show that the random forest model outperforms logistic regression and decision tree models in all performance metrics, demonstrating its effectiveness in predicting stroke risk. The study also pointed out problems such as data imbalance, feature engineering limitations, and insufficient model interpretability, suggesting more in-depth model optimization and exploration in future work. This study aims to provide an early prediction tool for stroke prevention and to support the development of more effective interventions.

【**Keywords**】Machine learning; stroke predictive analytics; decision trees; random forests; logistic regression